

Institut de Statistique, Biostatistique et Actuariat

**Analyse de la fréquence des sinistres en assurance :
GLM, réseaux de neurones, interprétabilité et segmentation des assurés.**

Prof du cours :	Rapport de projet réalisé dans le cadre du
	cours LDATS2310 :
Hainaut Donatien	Data Science for Finance and Insurance
	Master en science des données
	(orientation Statistique)
	par :
	Zeamari Yassine

Table des matières

Introduction	3
1 Apprentissage supervisé	4
1.1 Description des données et prétraitement	4
1.1.1 Description du jeu de données	4
1.1.2 Prétraitement des données	5
1.2 GLM benchmark	5
1.2.1 Présentation du modèle	5
1.2.2 Résultats	6
1.3 Neural networks	6
1.3.1 Architecture	6
1.3.2 Résultats	7
1.4 Comparison by subgroups	8
1.5 Bias regularization	9
1.5.1 Résultats et Analyse	10
1.6 Outils d'interprétation des modèles	11
1.6.1 Partial Dependence Plots (PDP)	11
1.6.2 ICE plots	13
1.7 Analyse locale des prédictions : LIME et valeurs de Shapley	15
1.7.1 Résultats et Analyse	15
2 Apprentissage non supervisé	17
2.1 Auto-encodeurs	17
2.1.1 Résultats	18
2.2 Variational Auto-Encoder	18
2.2.1 Résultats	19
2.3 Clustering avec l'algorithme K-means	19
2.4 Fréquence moyenne des sinistres par cluster	21
Conclusion	22
A Annexes	23
A.1 Résultats supplémentaires par sous-groupes	24

Introduction

Dans ce projet, différentes méthodes d'apprentissage supervisé et non supervisé sont étudiées pour analyser les fréquences de sinistres. Dans un premier temps, un modèle linéaire généralisé (GLM) est utilisé comme benchmark et comparé à plusieurs architectures de réseaux de neurones. Les performances des modèles sont évaluées à l'aide de la déviance de Poisson et des outils d'interprétation tels que les PDP, ICE, LIME et les valeurs de Shapley.

Dans une deuxième étape, l'étude de méthodes d'apprentissage non supervisé comme les autoencodeurs, les autoencodeurs variationnels (VAE) ou l'algorithme K-means, intervient pour analyser la structure des données et mettre en évidence différents profils d'assurés.

L'objectif de ce travail est donc de comparer ces différentes approches en termes de performance prédictive, d'interprétabilité et de capacité à représenter les profils de risque en assurance automobile.

Chapitre 1

Apprentissage supervisé

1.1 Description des données et prétraitement

1.1.1 Description du jeu de données

Le jeu de données utilisé dans ce projet provient de contrats d'assurance automobile et contient des informations relatives aux assurés, aux véhicules assurés ainsi qu'aux sinistres observés.

La variable cible considérée dans cette étude est la fréquence des sinistres, définie par :

$$Frquence = \frac{Nombre des sinistres}{Exposition au risque}$$

Les principales variables utilisées dans l'analyse sont les suivantes :

TABLE 1.1 – Description des variables du jeu de données

Variable	Description
Num_contrat	Numéro du contrat
IMMAT	Plaque d'immatriculation
Date_deb_situ	Date de début du contrat
ANNEE	Année
Date_fin_situ	Date de fin du contrat
Classe_age_situ_cont	Catégorie d'âge du contrat
Type_apporteur	Type d'intermédiaire (agent, courtier, autre)
Creation_entr	Indicateur de création récente de l'entreprise
Mode_gestion	Mode de gestion de la flotte
Activite	Activité du client
Zone	Zone géographique
Segment	Taille de la flotte
Fractionnement	Fréquence de paiement de la prime
Exposition_au_risque	Exposition au risque
Age_du_vehicule	Catégorie d'âge du véhicule
Valeur_puissance	Indicateur de puissance du véhicule
Franchise	Franchise du contrat
Nombre_vehicule	Nombre de véhicules
Valeur_assuree	Valeur assurée
Formule	Type de contrat
Categorie_ensemble	Catégorie du véhicule
Nombre_de_sinistre	Nombre de sinistres observés

1.1.2 Prétraitement des données

Avant l'estimation des modèles, plusieurs étapes de prétraitement ont été appliquées afin de rendre les données exploitables.

Les variables d'identification, telles que `Num_contrat` et `IMMAT`, ont été retirées car elles ne fournissent pas d'information pertinente pour la prédiction. Les variables `date_deb_situ` et `date_fin_situ` ont été supprimées lors du prétraitement car elles correspondent à des dates brutes difficilement exploitables directement par les modèles utilisés. Les variables ont ensuite été transformées en variables indicatrices à l'aide d'un encodage one-hot.

Afin d'évaluer la capacité de généralisation des modèles, les données ont été séparées en deux ensembles : 80 des observations ont été utilisées pour l'entraînement des modèles et les 20 restants pour la validation des performances.

1.2 GLM benchmark

1.2.1 Présentation du modèle

Le modèle linéaire généralisé (GLM) constitue l'approche de référence utilisée dans ce projet pour la modélisation de la fréquence des sinistres.

La variable cible considérée dans cette étude correspond à la fréquence des sinistres :

$$Y_i = \frac{N_i}{\nu_i},$$

où :

- N_i représente le nombre de sinistres observés pour le contrat i ,
- ν_i représente l'exposition au risque,
- Y_i correspond à la fréquence des sinistres.

Dans le cadre du GLM, on suppose que :

$$E(Y_i) = \mu_i,$$

où μ_i représente la fréquence moyenne prédite par le modèle.

Le modèle relie ensuite cette moyenne aux variables explicatives via une fonction de lien $g(\cdot)$:

$$g(\mu_i) = X_i^\top \beta,$$

où β désigne le vecteur des paramètres du modèle.

Dans ce projet, un modèle de Poisson avec fonction de lien logarithmique est utilisé, ce qui conduit à :

$$\log(\mu_i) = X_i^\top \beta.$$

L'estimation du modèle est réalisée à l'aide de la classe `TweedieRegressor` avec `power=1`, correspondant au cas particulier de la loi de Poisson. L'exposition au risque est utilisée comme pondération lors de l'apprentissage du modèle.

1.2.2 Résultats

Les performances du modèle GLM ont été évaluées à l'aide de la déviance de Poisson sur les ensembles d'entraînement et de validation.

TABLE 1.2 – Performance du modèle GLM

Ensemble	Déviance de Poisson
Train	0.6665
Validation	0.6238

Les performances obtenues avec le modèle GLM apparaissent globalement cohérentes entre les ensembles d'entraînement et de validation. La déviance calculée sur les données de validation est même légèrement inférieure à celle observée sur les données d'entraînement, ce qui indique une bonne capacité de généralisation du modèle et ne met pas en évidence de signe marqué de surapprentissage.

1.3 Neural networks

1.3.1 Architecture

Plusieurs réseaux de neurones ont été ajustés afin de prédire la fréquence des sinistres. Les modèles ont été programmés avec la bibliothèque `Keras`.

Les réseaux considérés sont des réseaux de neurones entièrement connectés. Les couches cachées utilisent la fonction d'activation `tanh`, tandis que la couche de sortie contient un seul neurone avec une fonction d'activation exponentielle.

La fonction de perte utilisée est la perte de Poisson, adaptée à la modélisation des fréquences de sinistres. L'optimisation des paramètres est réalisée à l'aide de l'algorithme Adam. Un mécanisme d'early stopping est également utilisé afin de limiter le risque de surapprentissage.

L'apprentissage est réalisé sur un maximum de 80 époques avec une taille de batch de 1000 observations. L'exposition au risque est utilisée comme pondération (`sample_weight`) afin de donner davantage d'importance aux contrats ayant une exposition plus élevée.

Quatre architectures ont été testées :

TABLE 1.3 – Architectures des réseaux de neurones testés

Modèle	Couches cachées	Activation	Dropout	L2	Learning rate	Epochs max
NN1	(48)	tanh	0.00	0.0	10^{-3}	80
NN2	(64, 48)	tanh	0.10	0.0	10^{-3}	80
NN3	(96, 64)	tanh	0.20	10^{-5}	5×10^{-4}	80
NN4	(128, 64, 32)	tanh	0.15	10^{-4}	5×10^{-4}	80

Pour chaque modèle, les performances sont évaluées à l'aide de la déviance de Poisson sur les ensembles d'entraînement et de validation. L'architecture retenue est celle qui minimise la déviance sur l'ensemble de validation.

1.3.2 Résultats

TABLE 1.4 – Résultats des réseaux de neurones

Modèle	Couches cachées	Dropout	L2	Train deviance	Validation deviance
NN1	(48)	0.00	0.0	0.6623	0.6280
NN2	(64, 48)	0.10	0.0	0.6827	0.641137
NN3	(96, 64)	0.20	10^{-5}	0.68625	0.646343
NN4	(128, 64, 32)	0.15	10^{-4}	0.69835	0.65515

Les résultats montrent que le modèle NN1 a la déviance la plus faible sur l'ensemble de validation et est donc l'architecture la plus performante parmi celles considérées. À l'inverse, les architectures plus complexes, comportant davantage de couches, du dropout ou une régularisation L2, ne permettent pas d'améliorer les performances dans ce contexte.

Les déviations d'entraînement et de validation restent relativement proches pour l'ensemble des modèles, ce qui suggère une absence de surapprentissage important et une bonne capacité de généralisation.

1.4 Comparison by subgroups

Afin d'évaluer la qualité des prédictions au-delà de la performance globale, les fréquences observées ont été comparées aux fréquences prédites par le GLM et le meilleur réseau de neurones (NN1) sur plusieurs sous-groupes du portefeuille.

Pour un groupe donné G , la fréquence observée est calculée par :

$$\text{freq}_{obs}(G) = \frac{\sum_{i \in G} N_i}{\sum_{i \in G} \nu_i},$$

où N_i représente le nombre de sinistres et ν_i l'exposition au risque.

De manière similaire, les fréquences prédites par les modèles sont calculées comme des moyennes pondérées par l'exposition :

$$\text{freq}_{pred}(G) = \frac{\sum_{i \in G} \nu_i \hat{Y}_i}{\sum_{i \in G} \nu_i},$$

où $\hat{Y}_i$ est la fréquence prédite par le modèle.

Les comparaisons ont été réalisées au niveau global ainsi que pour plusieurs variables explicatives importantes, notamment la zone géographique, la puissance du véhicule, la catégorie d'âge du contrat, la franchise, l'activité et l'âge du véhicule.

TABLE 1.5 – Comparaison par zone

Zone	Expo	Obs	GLM	NN
1	1747.58	0.0881	0.1002	0.1058
2	1463.09	0.1114	0.1109	0.1144
3	2814.14	0.1126	0.1233	0.1261
4	724.26	0.1229	0.1353	0.1407
5	848.55	0.1485	0.1458	0.1538
6	85.33	0.1289	0.1576	0.1719

TABLE 1.6 – Comparaison selon la puissance

Puiss.	Expo	Obs	GLM	NN
1	92.50	0.0757	0.0655	0.0759
2	108.39	0.0830	0.0727	0.0814
3	168.47	0.1128	0.0963	0.1042
4	1724.01	0.0980	0.0997	0.1040
5	1119.31	0.0983	0.1038	0.1067
6	494.97	0.1010	0.1108	0.1149
7	1760.49	0.0994	0.1250	0.1280
8	1107.18	0.1355	0.1397	0.1451
9	1065.75	0.1529	0.1542	0.1610
10	36.71	0.2179	0.1804	0.1843
11	5.17	0.0000	0.1597	0.1760

TABLE 1.7 – Comparaison selon la franchise

Franchise	Expo	Obs	GLM	NN
0	163.95	0.1220	0.1360	0.1708
1-200	3274.90	0.1069	0.1166	0.1201
201-300	2478.78	0.1162	0.1213	0.1245
301-400	1238.83	0.1179	0.1203	0.1244
401-600	342.07	0.1082	0.1218	0.1274
> 600	184.42	0.1030	0.1309	0.1379

TABLE 1.8 – Comparaison selon l'âge du véhicule

Âge	Expo	Obs	GLM	NN
≤ 5 ans	5086.38	0.1396	0.1451	0.1505
> 5 ans	2596.57	0.0578	0.0700	0.0726

Les résultats indiquent que le GLM et le réseau de neurones parviennent globalement à reproduire les principales structures présentes dans les données . En particulier, l’augmentation de la fréquence des sinistres selon certaines zones géographiques et selon la puissance du véhicule est correctement prise en compte par les deux approches.

Concernant l’âge du véhicule, les véhicules récents présentent une fréquence de sinistres plus élevée que les véhicules plus anciens. Cette différence est également correctement reproduite par les modèles.

Le réseau de neurones tend toutefois à prédire des fréquences légèrement plus élevées que le GLM pour plusieurs sous-groupes. Des écarts plus importants apparaissent également dans certaines catégories contenant peu d’observations, ce qui peut s’expliquer par une variabilité plus importante due au faible volume de données disponible. Les résultats détaillés pour les autres sous-groupes (`type_apporteur`, `formule`, `activite`, `mode_gestion`, `fractionnement`, etc.) sont présentés en annexe [A.1](#).

1.5 Bias regularization

Dans les modèles de fréquence, il est important de vérifier que la moyenne globale des prédictions reste cohérente avec la moyenne empirique observée dans les données. Cette propriété est appelée *balance property*.

La moyenne empirique pondérée par les expositions est définie par :

$$\bar{\mu} = \frac{\sum_{i=1}^n \nu_i Y_i}{\sum_{i=1}^n \nu_i},$$

où Y_i représente la fréquence observée et ν_i l’exposition au risque.

De manière similaire, la moyenne prédite par le modèle est donnée par :

$$\hat{\mu} = \frac{\sum_{i=1}^n \nu_i \hat{Y}_i}{\sum_{i=1}^n \nu_i},$$

où $\hat{Y}_i$ correspond à la fréquence prédite par le réseau de neurones.

Le biais global du modèle est alors mesuré par :

$$\text{bias} = \bar{\mu} - \hat{\mu}.$$

Lorsque ce biais est non nul, les prédictions peuvent être corrigées afin de restaurer la balance property. Une correction multiplicative est appliquée :

$$\hat{Y}_i^{BP} = \frac{\bar{\mu}}{\hat{\mu}} \hat{Y}_i.$$

Cette correction permet d’aligner la moyenne globale des prédictions sur la moyenne empirique observée tout en conservant les différences relatives entre les observations.

Les fréquences corrigées sont ensuite comparées aux fréquences observées sur plusieurs sous-groupes du portefeuille.

1.5.1 Résultats et Analyse

Les fréquences prédites avant et après correction du biais ont été comparées sur plusieurs sous-groupes du portefeuille.

Les résultats 1.13 montrent une chose : corriger le biais rend généralement les prédictions plus fiables. Et cela vaut autant pour les modèles GLM que pour les réseaux de neurones. Après avoir fait ces réglages, les fréquences qu'on prédisait sont devenues, dans l'ensemble, bien plus proches de celles qu'on a réellement constatées, et cela se vérifie dans la majorité des sous-groupes sur lesquels on a travaillé.

Pour les zones géographiques, les deux modèles parviennent à bien reproduire l'augmentation progressive du risque entre les différentes catégories. Avant la correction, le réseau de neurones avait toutefois tendance à prédire des fréquences légèrement trop élevées, surtout dans les zones les plus risquées. L'ajustement du biais permet alors de réduire cette surestimation tout en conservant les écarts relatifs entre les différentes zones. Des observations similaires peuvent être faites pour la puissance du véhicule. Dans l'ensemble, la fréquence des sinistres augmente avec la puissance, et cette évolution reste correctement capturée après correction. Les différences les plus importantes apparaissent principalement pour certaines catégories contenant peu d'observations, en particulier les puissances les plus élevées, où les estimations sont naturellement plus sensibles à la variabilité des données.

Les mêmes conclusions peuvent également être tirées pour les autres sous-groupes étudiés, en particulier la franchise et l'âge du véhicule. Dans l'ensemble, les modèles reproduisent correctement les structures présentes dans les données, tandis que la correction du biais améliore la concordance entre les fréquences prédites et les fréquences observées.

TABLE 1.9 – Correction du biais par zone (b : avant correction, a : après correction)

Zone	Obs	GLM _{b}	GLM _{a}	NN _{b}	NN _{a}
1	0.0881	0.1002	0.0937	0.1061	0.0958
2	0.1114	0.1109	0.1037	0.1159	0.1046
3	0.1126	0.1233	0.1153	0.1258	0.1135
4	0.1229	0.1353	0.1265	0.1394	0.1258
5	0.1485	0.1458	0.1364	0.1512	0.1364
6	0.1289	0.1576	0.1474	0.1728	0.1560

TABLE 1.10 – Correction du biais selon l'âge du véhicule (b : avant correction, a : après correction)

Âge	Obs	GLM _{b}	GLM _{a}	NN _{b}	NN _{a}
≤ 5 ans	0.1396	0.1451	0.1357	0.1503	0.1356
> 5 ans	0.0578	0.0700	0.0654	0.0727	0.0656

TABLE 1.11 – Correction du biais selon la puissance du véhicule (b : avant correction, a : après correction)

Puiss.	Obs	GLM _{b}	GLM _{a}	NN _{b}	NN _{a}
1	0.0757	0.0655	0.0612	0.0714	0.0645
2	0.0830	0.0727	0.0679	0.0780	0.0704
3	0.1128	0.0963	0.0901	0.1040	0.0938
4	0.0980	0.0997	0.0933	0.1027	0.0927
5	0.0983	0.1038	0.0970	0.1070	0.0965
6	0.1010	0.1108	0.1036	0.1147	0.1035
7	0.0994	0.1250	0.1169	0.1290	0.1164
8	0.1355	0.1397	0.1307	0.1454	0.1312
9	0.1529	0.1542	0.1442	0.1596	0.1440
10	0.2179	0.1804	0.1687	0.2116	0.1909
11	0.0000	0.1597	0.1493	0.1782	0.1608

TABLE 1.12 – Correction du biais selon la franchise (b : avant correction, a : après correction)

Franchise	Obs	GLM _{b}	GLM _{a}	NN _{b}	NN _{a}
0	0.1220	0.1360	0.1272	0.1708	0.1541
1-200	0.1069	0.1166	0.1090	0.1201	0.1084
201-300	0.1162	0.1213	0.1135	0.1245	0.1124
301-400	0.1179	0.1203	0.1125	0.1244	0.1122
401-600	0.1082	0.1218	0.1139	0.1274	0.1149
> 600	0.1030	0.1309	0.1224	0.1379	0.1244

TABLE 1.13 – Correction du biais pour différents sous-groupes (zone, âge du véhicule, puissance et franchise)

1.6 Outils d'interprétation des modèles

Afin d'identifier les variables qui discriminent le mieux la fréquence des sinistres, des outils d'interprétation des modèles ont été utilisés, notamment les *Partial Dependence Plots* (PDP) et les *Individual Conditional Expectation* (ICE) plots.


1.6.1 Partial Dependence Plots (PDP)

Les *Partial Dependence Plots* (PDP) permettent d'étudier l'influence moyenne d'une variable explicative sur la fréquence prédite par le modèle. Pour cela, les prédictions sont moyennées sur l'ensemble des observations, ce qui permet d'obtenir une représentation globale de l'effet de chaque variable sur la réponse du modèle.


Quand on regarde les graphiques 1.1, on voit que certaines variables semblent avoir davantage d'influence sur les prédictions du modèle. Les voitures les plus puissantes, surtout celles des catégo-

ries 8 et 9, ont visiblement plus d'accidents. On voit aussi une différence selon la région : la zone 5 a un risque d'accident bien plus grand que les autres, qui elles, sont plutôt proches les unes des autres. L'âge de la voiture compte aussi : les modèles récents, ceux qui ont moins de 5 ans, ont plus souvent des sinistres que les plus anciens. Par contre, les variables liées à l'activité montrent des écarts plus faibles entre catégories. Pour formule, la catégorie 2 est nettement plus élevée. Enfin, le montant pour lequel la voiture est assurée montre des différences plus claires entre les catégories.


Globalement, les PDP confirment que la puissance du véhicule, la zone géographique, l'âge du véhicule et la valeur assurée figurent parmi les variables les plus discriminantes pour expliquer la fréquence des sinistres.




(a) PDP de la puissance du véhicule




(b) PDP de la zone géographique




(c) PDP de l'âge du véhicule



(d) PDP de l'activité



(e) PDP de la valeur assurée




(f) PDP de la formule


FIGURE 1.1 – Partial Dependence Plots des principales variables explicatives

1.6.2 ICE plots


Les ICE plots complètent cette analyse en représentant l'effet d'une variable pour chaque observation individuellement. Contrairement aux PDP, ils permettent de mettre en évidence l'hétérogénéité des comportements entre les contrats.




(a) ICE plot de valeur puissance catégorie 9



(b) ICE plot de la zone 5



(c) ICE plot de l'âge du vehicule



(d) ICE plot de la valeur assuree 38K - 76K

FIGURE 1.2 – ICE plots des principales variables explicatives

Pour la catégorie de puissance `valeurpuissance_9`, la plupart des courbes montrent une augmentation de la fréquence prédite lorsque la variable passe de 0 à 1. Cela indique que les véhicules appartenant à cette catégorie de puissance sont généralement associés à un niveau de risque plus élevé. Une observation similaire peut être faite pour la variable `zone_5`. Pour une grande partie des contrats, l'appartenance à cette zone géographique entraîne une hausse de la fréquence prédite des sinistres, ce qui confirme les tendances déjà observées avec les PDP. À l'inverse, les variables `age_du_vehicule_> 5 ans` et `valeur_assuree_38K-76K` semblent avoir un effet plutôt négatif sur les prédictions. Dans la majorité des cas, les courbes diminuent lorsque ces variables prennent la valeur 1, ce qui correspond à une réduction du risque estimé par le modèle.

1.7 Analyse locale des prédictions : LIME et valeurs de Shapley

Afin d'interpréter localement les prédictions du réseau de neurones, deux outils d'explicabilité ont été utilisés : LIME (*Local Interpretable Model-agnostic Explanations*) et les valeurs de Shapley.

LIME consiste à approximer localement le comportement du modèle complexe par un modèle interprétable plus simple autour d'une observation donnée. Cette méthode permet d'identifier les variables qui contribuent le plus à la prédiction d'un contrat particulier.


Les valeurs de Shapley proviennent de la théorie des jeux coopératifs et permettent de mesurer la contribution de chaque variable à la prédiction finale du modèle. Contrairement à LIME, les contributions sont calculées de manière additive afin d'expliquer précisément l'écart entre la prédiction individuelle et la prédiction moyenne du portefeuille.

Deux polices ont été sélectionnées à partir des prédictions du réseau de neurones. La première correspond à la plus faible fréquence prédite, tandis que la seconde correspond à la plus forte fréquence prédite :

$$i_{\text{low}} = \arg \min_i \hat{Y}_i, \quad i_{\text{high}} = \arg \max_i \hat{Y}_i.$$

Cette sélection permet de comparer deux profils opposés en termes de risque prédit.

1.7.1 Résultats et Analyse



(a) Explication LIME pour la police à faible risque (b) Explication LIME pour la police à risque élevé

FIGURE 1.3 – Explication LIME

Les résultats 1.3 obtenus avec LIME permettent d'identifier les variables ayant le plus d'influence sur les prédictions individuelles du réseau de neurones.

Pour la police à faible risque 1.3a, certaines catégories comme `valeur_assuree_76K-137K` contribue fortement à réduire la fréquence prédite. Certaines catégories liées à la puissance du véhicule, à la formule du contrat ou à la franchise présentent également des contributions négatives au risque estimé.

Concernant la police à risque élevé 1.3b, plusieurs variables augmentent la fréquence prédite, notamment la catégorie `valeurpuissance_9`, la zone géographique `zone_5` ainsi que certaines modalités de fractionnement. À l'inverse, certaines catégories liées à l'âge du véhicule `age_du_vehicule_> 5`, à l'activité `activite_3`, `activite_6` ou à la formule `formule_3`, `formule_5` contribuent à diminuer légèrement la prédiction.

Les résultats montrent également que les variables les plus influentes peuvent changer sensiblement d'une police à l'autre, ce qui illustre le caractère local des explications fournies par LIME.




FIGURE 1.4 – Valeurs de Shapley

Pour la police à risque élevé 1.4a, plusieurs variables augmentent fortement la fréquence prédite, notamment la catégorie géographique `zone_5` ainsi que la catégorie de puissance `valeurpuissance_9`. Certaines modalités liées au fractionnement, à l'activité ou à la formule du contrat contribuent également positivement au risque estimé.

À l'inverse, certaines variables comme `formule_3`, certaines catégories de franchise ou certaines classes d'âge contribuent négativement à la prédiction.

Concernant la police à faible risque 1.4b, plusieurs variables réduisent fortement la fréquence prédite, notamment `valeur_assuree_76K-137K`, `formule_5` ainsi que la catégorie `age_du_vehicule_> 5 ans`. D'autres modalités liées à la puissance du véhicule ou au mode de gestion contribuent également à diminuer le risque estimé.

Les valeurs de Shapley fournissent ainsi une interprétation additive claire des prédictions du modèle et permettent d'identifier précisément les variables les plus influentes pour chaque contrat individuel.

Chapitre 2

Apprentissage non supervisé

Cette partie du projet s'intéresse à l'analyse non supervisée du portefeuille d'assurance. Contrairement aux approches supervisées utilisées précédemment, les méthodes non supervisées ne reposent pas directement sur la variable cible représentant la fréquence des sinistres.

L'objectif principal est d'identifier des structures ou des regroupements naturels dans les données à partir des caractéristiques des contrats. Deux approches ont été étudiées :

- les auto-encodeurs et les variational auto-encodeurs (VAE), utilisés afin d'apprendre une représentation compressée des données ;
- l'algorithme de clustering K-means, utilisé afin d'identifier différents groupes de contrats présentant des caractéristiques similaires.

Les variables retenues correspondent principalement aux caractéristiques des contrats et des véhicules :

TABLE 2.1 – Variables utilisées pour l'apprentissage non supervisé

Variables	Variables
Type_apporteur	Fractionnement
Creation_entr	Age_du_vehicule
Mode_gestion	Valeur_puissance
activite	formule
Zone	Categorie_ensemble
Segment	

Les variables catégorielles ont été transformées par encodage one-hot avant l'apprentissage des modèles. Les données ont ensuite été séparées en un ensemble d'entraînement et un ensemble de validation selon une proportion 80/20.

2.1 Auto-encodeurs

Deux auto-encodeurs classiques ont été entraînés afin d'apprendre une représentation compressée des variables explicatives utilisées dans la partie non supervisée.

Un auto-encodeur est composé de deux parties : un encodeur, qui projette les données dans un espace latent de plus faible dimension, et un décodeur, qui reconstruit les données initiales à

partir de cette représentation latente. La qualité de reconstruction est mesurée à l’aide de l’erreur quadratique moyenne :

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n \|X_i - \hat{X}_i\|^2.$$

Les deux modèles utilisent la fonction d’activation `tanh` dans les couches cachées et une activation linéaire dans la couche de sortie. L’optimisation est réalisée avec l’algorithme `RMSprop`, et la fonction de perte est la `MeanSquaredError`. Les modèles sont entraînés pendant 30 époques avec une taille de batch de 300.

TABLE 2.2 – Architectures des auto-encodeurs classiques

Modèle	Architecture	Dimension latente	Activation
AE1	32 – 16 – 8 – 16 – 32	8	tanh
AE2	64 – 40 – 16 – 40 – 64	16	tanh

2.1.1 Résultats

Les performances des deux auto-encodeurs ont été évaluées à l’aide de l’erreur quadratique moyenne (MSE) calculée sur les ensembles d’entraînement et de validation.

TABLE 2.3 – Performances des auto-encodeurs classiques

Modèle	Train MSE	Validation MSE
AE1	0.00424	0.00415
AE2	0.00199	0.00200

Les résultats sont clairs : le modèle AE2 est nettement meilleur que l’AE1. Il affiche une erreur de reconstruction plus faible, à la fois sur les données d’entraînement et sur celles de validation. Ça veut dire qu’AE2 comprend et reproduit bien mieux la structure réelle des données. La différence s’explique surtout par son architecture plus profonde et sa dimension latente plus grande, qui lui permettent de garder beaucoup plus d’informations pendant la compression, au lieu de tout écraser comme le fait AE1.

2.2 Variational Auto-Encoder

Deux VAE ont été testés afin de comparer l’impact de la dimension latente et de la taille de l’architecture sur la qualité de reconstruction. Le premier modèle, noté VAE1, utilise une dimension latente égale à 4 et une couche cachée de 32 neurones. Le second modèle, noté VAE2, utilise une dimension latente égale à 8 et une couche cachée de 64 neurones.

TABLE 2.4 – Architectures des VAE testés

Modèle	Couche cachée	Dimension latente	Activation
VAE1	32	4	tanh
VAE2	64	8	tanh

La fonction de perte du VAE combine deux termes : une erreur de reconstruction pondérée et une divergence de Kullback-Leibler. Les modèles sont entraînés pendant 30 époques avec une taille de batch de 300 à l’aide de l’optimiseur RMSprop.

2.2.1 Résultats

Les performances des variational auto-encoders ont été évaluées à l’aide de l’erreur quadratique moyenne (MSE) calculée sur les ensembles d’entraînement et de validation.

TABLE 2.5 – Performances des variational auto-encodeurs

Modèle	Train MSE	Validation MSE
VAE1	0.2818	0.2823
VAE2	0.2734	0.2743

On observe que le modèle VAE2 reconstruit les données de manière un peu plus précise que VAE1. Cette amélioration peut être liée à l’utilisation d’une architecture plus développée ainsi qu’à un espace latent plus grand, offrant au modèle une capacité de représentation plus importante. Néanmoins, les performances des modèles VAE restent globalement inférieures à celles des auto-encodeurs classiques (AE) en termes d’erreur de reconstruction.

2.3 Clustering avec l’algorithme K-means

Le clustering K-means a été utilisé afin d’identifier des groupes d’observations présentant des caractéristiques similaires. Le principe de cette méthode repose sur la création de clusters homogènes, en regroupant les observations les plus proches les unes des autres dans l’espace des variables explicatives.

On a testé différentes valeurs de K , de 2 à 20, afin de trouver le nombre optimal de clusters. Pour chaque K , l’inertie intra-cluster et le coefficient de silhouette ont été calculés. Les résultats montrent un coefficient de silhouette maximal pour $K = 2$ (voir le tableau 2.6). Cela indique que la meilleure partition. Dans la suite de l’analyse, le modèle K-means est donc estimé avec deux clusters. Chaque contrat est ensuite affecté au groupe dont le profil est le plus proche dans l’espace des variables explicatives.

TABLE 2.6 – Résultats du clustering K-means

K	Inertie	Silhouette
2	757349.44	0.3341
3	612727.63	0.2913
4	496663.78	0.2779
5	456557.38	0.2532
6	431210.38	0.2345
7	406810.09	0.2055
8	387787.31	0.2027
9	370503.50	0.2032
10	353561.97	0.1860
11	346495.50	0.1792
12	335167.13	0.1703
13	324572.47	0.1696
14	318011.63	0.1705
15	311023.66	0.1685
16	305764.44	0.1557
17	299691.94	0.1625
18	293230.69	0.1601
19	289702.75	0.1614
20	281280.06	0.1654

TABLE 2.7 – Catégories dominantes dans chaque cluster

Variable	Cluster 0	Cluster 1
Taille du cluster	39 888	47 340
type_apporteur	1 (72%)	1 (70%)
creation_entr	1 (96%)	1 (81%)
mode_gestion	N (72%)	N (59%)
activite	7 (43%)	1 (44%)
zone	3 (38%)	3 (36%)
segment	1 (56%)	2 (54%)
fractionnement	T (43%)	T (43%)
age_du_vehicule	≤ 5 ans (67%)	≤ 5 ans (67%)
formule	3 (85%)	3 (73%)
categorie_ensemble	1 (100%)	1 (100%)

Les deux clusters 2.7 présentent des profils relativement différents sur certaines variables. Le cluster 0 est principalement caractérisé par des contrats appartenant au segment 1, une activité dominante de type 7 ainsi qu’une forte proportion de contrats associés à la formule 3. Le cluster 1 regroupe davantage de contrats appartenant au segment 2 et à l’activité 1.

Ces résultats montrent que l’algorithme K-means permet d’identifier différents profils d’assurés à partir des caractéristiques des contrats, même si certaines variables restent relativement proches entre les groupes.

2.4 Fréquence moyenne des sinistres par cluster

Afin d'évaluer les différences de risque entre les groupes obtenus par K-means, une fréquence moyenne de sinistres a été calculée pour chaque cluster.

La fréquence moyenne associée à un cluster C_k est calculée : $\text{freq}_k = \frac{\sum_{i \in C_k} N_i}{\sum_{i \in C_k} \nu_i}$,

Les fréquences obtenues pour chaque cluster ont ensuite été utilisées pour calculer une déviance de Poisson, afin d'évaluer la qualité du clustering et de comparer ses performances à celles du GLM et du réseau de neurones.

TABLE 2.8 – Fréquence moyenne observée par cluster

Cluster	Fréquence moyenne
0	0.1206
1	0.1170

La déviance obtenue avec les fréquences moyennes des clusters est donnée par :

$$\text{Deviance} = 0.6754.$$

Cette valeur reste plus élevée que celles obtenues avec le GLM et les réseaux de neurones. Cela s'explique par le fait que le clustering K-means utilise uniquement une segmentation globale des contrats, tandis que les modèles supervisés exploitent directement l'information contenue dans les fréquences de sinistres afin d'optimiser les prédictions. Les résultats montrent néanmoins que les clusters identifiés présentent des profils de risque légèrement différents, avec une fréquence moyenne plus élevée dans le cluster 0 que dans le cluster 1.

Conclusion

Dans ce projet, plusieurs approches de modélisation ont été étudiées afin d’analyser la fréquence des sinistres dans un portefeuille d’assurance automobile.

Dans la partie supervisée, plusieurs modèles ont été étudiés, incluant un GLM de Poisson et différentes architectures de réseaux de neurones. Les résultats obtenus montrent que le réseau de neurones retenu présente des performances comparables à celles du GLM, avec des améliorations observées pour certains sous-groupes du portefeuille. En parallèle, l’utilisation de méthodes d’interprétation telles que les PDP, les ICE plots, LIME ou les valeurs de Shapley a permis de mieux comprendre les prédictions produites par les modèles. Ces analyses soulignent notamment l’influence importante de variables comme la puissance du véhicule, la zone géographique ainsi que certaines caractéristiques propres au contrat. Du côté des approches non supervisées, des auto-encodeurs classiques et variationnels ont été utilisés afin d’extraire des représentations plus compactes des données. Les résultats obtenus montrent que les auto-encodeurs classiques reconstruisent globalement mieux les données que les VAE. Par la suite, l’utilisation de K-means a permis de distinguer plusieurs profils d’assurés, même si les niveaux moyens de sinistralité observés entre les groupes restent relativement proches.

Annexe A

Annexes

A.1 Résultats supplémentaires par sous-groupes

TABLE A.1 – Comparaison selon le type d’apporteur

Type	Expo	Obs	GLM	NN
1	4915.69	0.1166	0.1217	0.1255
2	1796.04	0.1136	0.1252	0.1334
3	971.22	0.0855	0.0996	0.0996

TABLE A.3 – Comparaison selon l’activité

Act.	Expo	Obs	GLM	NN
1	2036.97	0.1311	0.1239	0.1302
2	254.24	0.0944	0.1078	0.1165
3	1512.43	0.0893	0.1136	0.1156
4	600.06	0.0950	0.1239	0.1298
5	214.79	0.0978	0.1028	0.1022
6	879.07	0.0842	0.1120	0.1150
7	1425.02	0.1284	0.1258	0.1295
8	760.37	0.1302	0.1235	0.1285

TABLE A.5 – Comparaison selon le fractionnement

Frac.	Expo	Obs	GLM	NN
A	2605.46	0.1194	0.1168	0.1244
S	1971.36	0.1253	0.1273	0.1293
T	3106.13	0.0972	0.1173	0.1204

TABLE A.2 – Comparaison selon la formule

Formule	Expo	Obs	GLM	NN
2	2.19	0.0000	0.0775	0.0992
3	5588.38	0.1197	0.1269	0.1319
4	967.34	0.0827	0.0997	0.0997
5	1125.04	0.0987	0.1014	0.1060

TABLE A.4 – Comparaison selon le mode de gestion

Mode	Expo	Obs	GLM	NN
N	3734.17	0.1074	0.1178	0.1226
P	3948.78	0.1162	0.1215	0.1254

TABLE A.6 – Comparaison selon la catégorie d’âge

Catégorie	Expo	Obs	GLM	NN
1-2 ans	1230.43	0.1195	0.1245	0.1413
2-3 ans	1163.04	0.0954	0.1152	0.1170
3-4 ans	1137.01	0.1091	0.1189	0.1219
4-5 ans	985.07	0.1107	0.1208	0.1225
≤ 1 an	1720.21	0.1110	0.1171	0.1195
> 5 ans	1447.19	0.1230	0.1223	0.1232