

PROJET : LDATS2350 Data Mining

ZEAMARI YASSINE 67522000 DATS2MS

1 INTRODUCTION

Dans le secteur de l'assurance automobile, pour réduire les coûts et mieux cibler les profils à risque, il est essentiel de se concentrer sur la prévention des risques liés aux sinistres. Dans ce projet, l'objectif principal est la prédiction de l'occurrence d'un accident pendant la durée de validité d'une police d'assurance à l'aide de techniques de data mining appliquées à un jeu de données réel.

La variable cible `claimNumberMD` est binaire : elle indique la présence ou l'absence d'un accident durant la période couverte par la police. Toutes les autres variables disponibles seront utilisées comme prédicteurs pour modéliser ce phénomène. Il s'agit d'un problème de classification.


2 Compréhension et préparation des données

2.1 Analyse exploratoire

Avant d'entraîner des modèles prédictifs, une analyse exploratoire des données est indispensable. Elle permet de comprendre la structure du jeu de données, de détecter certains problèmes (valeurs manquantes, outliers, distributions symétrie ou asymétrie).

2.1.1 analyse univariée


	uwYear	age	nYears	carVal	cover	density	claimNumbMD
count	24774.000000	24774.000000	24774.000000	24774.000000	24774.000000	24774.000000	24774.00000
mean	2009.508073	38.554937	5.256842	16772.358521	0.483612	127.219773	0.49556
std	0.499945	14.175220	4.563897	10664.288239	0.499741	82.321863	0.49999
min	2009.000000	18.000000	0.000000	1000.000000	0.000000	14.377142	0.00000
25%	2009.000000	27.000000	1.000000	8470.000000	0.000000	58.590404	0.00000
50%	2010.000000	37.000000	4.000000	15050.000000	0.000000	110.983678	0.00000
75%	2010.000000	48.000000	9.000000	22893.750000	1.000000	198.005304	1.00000
max	2010.000000	75.000000	15.000000	49995.000000	1.000000	297.385170	1.00000



- Les données révèlent plusieurs distributions asymétriques, notamment pour les variables nYears et density.
- Des outliers significatifs apparaissent principalement dans la variable carVal.

2.1.2 analyse bivariée

2.1.2.1 Numérique vs numérique



- Les variables continues montrent très peu de corrélations entre elles, suggérant qu'elles sont largement indépendantes.

2.1.2.2 Numérique vs Catégoriel

nous avons utilisé un test d'analyse de variance (ANOVA). Ce test permet de comparer les moyennes d'une variable numérique entre les différentes modalités d'une variable catégorielle ici les classes 0 (pas d'accident) et 1 (accident).

ANOVA pour age :

F-statistique = 1654.31, p-value = 0.00000
Différence significative

ANOVA pour nYears :

F-statistique = 86.22, p-value = 0.00000
Différence significative

ANOVA pour carVal :

F-statistique = 24.93, p-value = 0.00000
Différence significative

ANOVA pour density :

F-statistique = 636.23, p-value = 0.00000
Différence significative

Ces résultats confirment que les variables **age**, **nYears**, **carVal** et **density** présentent une forte influence sur la survenue d'un sinistre.

2.1.2.3 Catégoriel vs Catégoriel

Pour examiner les relations entre les variables catégorielles et la variable cible **claimNumberMD**, nous avons effectué des tests du χ^2 d'indépendance à partir de tableaux de contingence.







Variable	Chi ²	dof	p-value	Conclusion
uwYear	12.28	1	0.0005	Liée ($p < 0.05$)
gender	54.60	1	0	Liée ($p < 0.05$)
carType	88.17	4	0	Liée ($p < 0.05$)
carCat	181.3	4	0	Liée ($p < 0.05$)
job	1049.76	4	0	Liée ($p < 0.05$)
cover	142.71	1	0	Liée ($p < 0.05$)

- Le test du χ^2 montre que toutes les variables catégorielles testées sont significativement associées à **claimNumberMD**.

les graphiques de contingence montrent clairement les relations entre différentes variables catégorielles et la variable **claimNumberMD**.

- Il semble que la probabilité d'avoir un sinistre soit plus élevée pour les polices souscrites en 2010.
- Il y a un effet du genre sur la survenue des sinistres, les hommes semblent plus concernés.
- Le type de voiture influence donc le risque.

- Les petites voitures sont plus exposées au risque de sinistre que les voitures moyennes ou grandes.
- Les **employed** et **Housewife** semblent avoir une proportion de sinistres relativement élevée .
- Les personnes sans couverture (cover = 0) ont une proportion plus élevée de sinistres.



3 PRÉTRAITEMENT

3.1 Détection des doublons

L'ensemble de données contient 21 lignes dupliquées (0.085% des observations) identifiées comme des copies exactes sur toutes les variables (même `claimNumberMD`) ce qui peut correspondre à deux cas :

- Un même client avec deux contrats identiques
- Deux clients différents ayant exactement les mêmes caractéristiques (très rare).
- mais ces doublons résultent probablement d'erreurs de saisie ou d'import multiple.

- Aucune colonne supplémentaire (comme un ID client) ne justifiait leur maintien.
- Ils n'apportent pas d'information supplémentaire leur suppression ne changera ni les proportions ni les relations, donc on décide de les supprimer.

3.2 valeurs manquantes

Une vérification des valeurs manquantes a été effectuée, aucune variable ne présente de valeur manquante

Valeurs manquantes par colonne :

```
uwYear      0
gender      0
carType     0
carCat      0
job         0
age         0
nYears      0
carVal      0
cover       0
density     0
claimNumbMD 0
dtype: int64
```

3.3 traitement des outliers

Pour détecter les outliers, nous avons utilisé la méthode de l'IQR et la méthode Z-score.

Table 2: Analyse des outliers par variable


Variable	Outliers (Plage normale)	Outliers (Z-score > 3)	Plage normale
uwYear	0 (0.00%)	0	[2007.50, 2011.50]
age	0 (0.00%)	0	[-4.50, 79.50]
nYears	0 (0.00%)	0	[-11.00, 21.00]
carVal	648 (2.62%)	157	[-13167.50, 44532.50]
cover	0 (0.00%)	0	[-1.50, 2.50]
density	0 (0.00%)	0	[-154.51, 413.76]
claimNumbMD	0 (0.00%)	0	[-1.50, 2.50]

Seule la variable **carVal** présente des valeurs aberrantes significatives.

Étant donné que **carVal** est positive et présente une distribution asymétrique, nous avons appliqué une transformation par racine carrée **carVal_sqrt**.

Une nouvelle détection d'outliers a été réalisée sur la variable transformée:

```
Outliers dans carVal_sqrt: 0 (0.00%)
```




3.4 Standardisation des variables continues et Encodage des variables catégorielles

- Les variables numériques ont été standardisées à l'aide du **StandardScaler**, cela est particulièrement utile pour les algorithmes sensibles à l'échelle des données (ex : K-NN, SVM, régression logistique).
- Les variables catégorielles ont été transformées en variables numériques via un encodage one-hot.

4 Modélisation et comparaison des techniques

4.1 modèle de régression logistique


Nous avons ajusté un modèle de régression logistique afin de prédire la probabilité de survenue d'un sinistre (`claimNumbMD`):



L'AUC (Area Under Curve) est de 0.69, ce qui indique une performance modérée du modèle, La matrice de confusion révèle un taux de bonnes prédictions d'environ 63-66%.


4.2 Modèle d'Arbres de Décision

Le modèle d'arbre de décision a été utilisé aussi pour la prédiction de la variable cible, ce modèle présente l'avantage d'être interprétable, permettant de visualiser facilement les règles de décision issues des variables explicatives. il détecte environ 56% des sinistres, ce qui est acceptable mais pas optimal, L'AUC = 0.56 ce qui est à peine meilleur qu'un modèle aléatoire.




4.3 Modèle K-Nearest Neighbors

Le modèle K-NN a été optimisé à l'aide d'une validation croisée (GridSearchCV), ce qui a permis d'identifier le meilleur paramètre pour `n_neighbors=19`, la valeur de l'AUC est de 0.64, ce qui suggère une capacité de discrimination modeste




4.4 Réseaux de Neurones (MLP)



Le modèle de réseau de neurones (MLP) présente des performances très similaires à la régression logistique avec une AUC de 0.68, soit une capacité de discrimination légèrement inférieure, la matrice de confusion montre une amélioration notable dans la détection des vrais positifs mais cette amélioration s'accompagne d'une augmentation des faux positifs.

4.5 Naïve Bayes

Un modèle de classification Naïve Bayes a également été testé en raison de sa rapidité d'exécution et de sa simplicité



Le modèle Naïve Bayes affiche des performances légèrement inférieures aux modèles précédents avec une AUC de 0.67, la matrice de confusion révèle un profil de prédiction plus équilibré : le modèle identifie correctement 2988 vrais positifs avec seulement 689 faux négatifs une bonne sensibilité, mais il génère également 2213 faux positifs pour 1536 vrais négatifs, résultant en une spécificité plus faible.

5 COMPARAISON LES MODELES

le tableau ci-dessous présente les résultats des différents modèles de classification:

Model	Class	Precision	Recall	F1-score	Support	Accuracy
Regression Logistique	0	0.65	0.61	0.63	3749	0.64
	1	0.63	0.66	0.64	3677	
Arbre de Décision	0	0.65	0.61	0.63	3749	0.64
	1	0.63	0.66	0.64	3677	
KNN	0	0.61	0.62	0.62	3749	0.61
	1	0.61	0.59	0.60	3677	
MLP	0	0.61	0.62	0.62	3749	0.61
	1	0.61	0.59	0.60	3677	
Naive Bayes	0	0.69	0.41	0.51	3749	0.61
	1	0.57	0.81	0.67	3677	


on compare des modèles de classification selon leurs caractéristiques globales et leurs performances

Modèle	Avantages	Inconvénients
Régression Logistique	Interprétable, rapide, bonnes performances globales	Hypothèse de linéarité
Arbre de Décision	Interprétable, capture les interactions et la non-linéarité, Performance identique à la régression logistique	Risque de surapprentissage sans régularisation, il génère des faux positifs
KNN	Simple, non-paramétrique	Sensible au choix de K, performances globales faibles
MLP	Capable de modéliser des relations complexes	Temps de calcul élevé, peu interprétable, performance décevante
Naïve Bayes	Très rapide, excellent rappel sur la classe 1 (81%)	Très faible rappel pour la classe 0, performances déséquilibrées

La régression logistique et l'arbre de décision se distinguent comme les meilleurs compromis atteignant une accuracy de 64% et un F1-score équilibré. En plus de leurs performances correctes, ces modèles sont interprétables.

Cependant si l'on considère la capacité à bien discriminer les classes mesurée par l'AUC la régression logistique (AUC = 0.69) surpasse nettement l'arbre de décision (AUC = 0.56), cela indique que la régression logistique est plus fiable pour séparer les cas positifs et négatifs.

Par conséquent, la régression logistique reste le modèle recommandé, car elle combine de bonnes performances de classification, une bonne capacité de discrimination.



le graphique montre les 15 variables les plus influentes sur la probabilité d'un sinistre (`claimNumberMD`), parmi les facteurs réducteurs de risque, on trouve notamment la variable `job_Retired`, qui possède le coefficient le plus négatif cela suggère que les retraités sont significativement moins susceptibles de déclarer un sinistre, de même l'âge du conducteur plus élevé est associé à une probabilité plus faible de sinistre.

À l'inverse, certaines variables augmentent significativement le risque. par exemple les conducteurs avec un véhicule de `type E`, vivant dans des zones de forte densité (`density`), de sexe masculin (`gender_Male`) ou étant sans emploi (`job_Unemployed`) ont une probabilité plus élevée de déclarer un sinistre.

6 CONCLUSION

Ce projet visait à prédire la survenue d'un sinistre à l'aide de données client après nettoyage, exploration et essais de transformation des variables et plusieurs modèles ont été testés, la régression logistique est le meilleur compromis entre performance et interprétabilité.

Le modèle présente une performance modeste, probablement due à un manque de variables explicatives plus fines (ex. : historique complet, comportement de conduite), malgré des tentatives de feature engineering, les performances n'ont pas été significativement améliorées, cela suggère que les informations disponibles dans les données restent limitées.