

LSTAT2150 — Nonparametric Statistics (Smoothing Methods):Project on variance estimation for non-parametric regression

zeamari yassine

11/23/2024

introduction

Considérons le modèle de régression non paramétrique :

$$Y_i = m(X_i) + 0.5 \sigma(X_i) \varepsilon_i, \quad i = 1, \dots, n$$

où $X_i = \frac{i}{n} \in (0, 1]$, $\{\varepsilon_i\} \sim \mathcal{N}(0, 1)$, $m(x) = (\sin(2\pi x^3))^3$, $\sigma^2(x) = 2 + \sin(2\pi x)$.

Dans ce projet, nous nous intéressons à l'estimation la fonction de variance $\sigma^2(x)$, nous proposons deux approches pour l'estimer :

approche de h rdle et Vieu(1992) Cette approche se base sur la d composition de la variance conditionnelle :

$$\sigma^2(x) = E[Y^2|X = x] - m^2(x)$$

1. estimation de $E[Y^2|X = x]$:

on utilise un estimateur   noyau de forme :

$$\frac{\sum K\left(\frac{X_i - x}{h_2}\right) Y_i^2}{\sum K\left(\frac{X_i - x}{h_2}\right)}$$

  h_2 un parametre de lissage.

2. estimation $m^2(x)$: on utilise un estimateur non parametrique de $m(x)$, not  $\hat{m}_{h_1}(x)$.

3. estimation final:

$$\hat{\sigma}^2(x) = \frac{\sum_{i=1}^n K\left(\frac{X_i - x}{h_2}\right) Y_i^2}{\sum_{i=1}^n K\left(\frac{X_i - x}{h_2}\right)} - \hat{m}_{h_1}^2(x),$$

approche Fan and Yao(1998):

cette m thode bas e sur les r sidus:

1. calcul les r sidus:

$$\hat{\varepsilon}_i = Y_i - \hat{m}_{h_1}(X_i)$$

2.

Estimation de $m(x)$:

On estime d'abord la fonction de régression $\hat{m}_{h_1}(x)$.

3. Estimation de la variance :

$$\hat{\sigma}^2(x) = \frac{\sum_{i=1}^n K\left(\frac{X_i - x}{h_2}\right) \hat{\varepsilon}_i^2}{\sum_{i=1}^n K\left(\frac{X_i - x}{h_2}\right)}$$

Ces deux approches seront évaluées en simulant des ensembles de données, et leurs performances seront comparées sur des métriques telles que le biais moyen, la variance moyenne et le MSE.

la simulation deux méthodes:

Le modèle est défini comme:

$$Y_i = m(X_i) + u_i, \quad u_i = 0.5\sigma(X_i)\varepsilon_i,$$

où :

$$u_i \sim \mathcal{N}(0, 0.25\sigma^2(X_i)).$$

les étapes de la simulation:


1. Génération des données : .générer X_i .calculer $m(x)$ et $\sigma^2(X_i)$.calculer Y_i

2. estimation deux approches

3. Répétitions Monte Carlo: Répéter les étapes précédentes k=400 fois pour chaque méthode

avec $h_1 = h_2 = 0.1$ et n=100.

Comparison of True and Estimated Variance



A.analyse par region

pour la region $x \in [0.01, 0.25]$:


les deux méthode suivent correctement la tendance de la variance vraie et sont stable ,On observe l'estimation conditionnelle moins biaisé que Estimation par résidus quand $x > 0.1$

pour la region $x \in [0.25, 0.5]$:

les deux méthodes caprurent bien le pic et le changement de tendance,mais la méthode conditionnelle capture mieux les variations rapides et aussi plus biaisée que Estimation par résidus

pour la region $x \in [0.5, 1]$: la méthode par résidus plus précise et elle Suit la tendance plus fidèlement,bien que la méthode conditionnelle instable avec des oscillations et un grand ecart avec la vraie variance .

B.analyse des performances



nous comparons le MSE de deux methodes:

Le MSE de la méthode résiduelle reste globalement faible et plus stable sur tout l'intervalle de x , avec des variations minimales. Cela montre que cette méthode est moins sensible à la variation de x et offre une performance plus constante.

Le MSE de la méthode directe reste faible jusqu'au point $x=0.4$, le MSE augmente vite atteint un pic élevé autour de $x=0.8$, montrant une performance plus mauvaise dans cette zone

nous allons examiner les biais, la variance et l'erreur quadratique moyenne (MSE) des deux méthodes d'estimation (directe et résiduelle) aux différents points intéressants $x \in (0.01, 0.25, 0.75, 1)$ pour identifier les comportements et comparer leur efficacité.

	Estimation directe				Estimation par résidus			
	0.01	0.25	0.75	1	0.01	0.25	0.75	1
Le biais	0.2843	-0.2356	1.2153	0.0455	0.2585	-0.3109	0.3336	0.0252
La variance	0.0354	0.0295	0.0099	0.0278	0.00349	0.0287	0.0043	0.0268
MSE	0.1162	0.085	1.4868	0.0298	0.1018	0.1254	0.1156	0.0275

Table 1: Comparaison entre l'estimation directe et l'estimation par résidus.

1. au bord gauche (0.01) et droit (1):

l'estimateur résiduel semble légèrement plus performant, avec des biais et des MSE plus faibles. Les variances sont similaires et faibles.

Le biais de deux méthodes 0.2843 et 0.2585 ce qui explique l'écart observé dans la figure par rapport à la vraie variance au point $x=0.01$.

2. au point $x=0.25$ (le max):

L'estimateur direct a une MSE et un biais plus faible, suggérant une meilleure performance.

3. au point $x=0.75$ (le min):

Le biais de la méthode directe est significativement plus élevé, ce qui est problématique, la méthode résiduelle est clairement supérieure grâce à un biais et une MSE nettement plus faibles.


Une analyse plus approfondie pourrait inclure l'ajustement des paramètres de lissage (h_1 et h_2) pour optimiser les performances.

Étude de la sensibilité aux paramètres de lissage

les paramètres de lissage h_1 et h_2 jouent un rôle crucial dans l'estimation de la variance .

Nous allons étudier leur impact sur les deux méthodes d'estimation : l'estimation conditionnelle et l'estimation par résidus.

l'évolution des estimateurs en fonction des différentes valeurs de h_1 en fixant h_2



A.Impact de h_1 sur les estimations conditionnelles:

Lorsque h_1 est petit ($h_1 = 0.02$ ou $h_1 = 0.04$) suit très étroitement les variations rapides de la vraie variance, Cependant Beaucoup d'oscillations, particulièrement autour de $x = 0.6 - 0.9$ donc elle est sensible au bruit, ce qui entraîne une plus grande instabilité.

quand on augmente h_1 par exemple $h_1 = 0.08$ ou $h_1 = 0.1$ l'estimation conditionnelle devient plus lisse et moins influencée par le bruit ,elle peut manquer certains détails de les variations rapides.

lorsque h_1 est grande l'estimation devient trop lisse ,Perte significative des détails de la vraie variance , le biais augmente.


B.Impact de h_1 sur les estimations résiduelles :

lorsque h_1 est petite la méthode résiduelle devient de plus en plus proche de la vraie valeur,elle est plus stable et pas affectés par les variations dues au bruit. quand h_1 augmente elle Perte des détails fins mais conserve la tendance générale et sur-lissage pour $h_1 = 0.2$ et aussi le biais devient important.

en générale la Variation de h_1 : - Augmenter h_1 lisse davantage l'estimation de $m(x)$, ce qui peut réduire la variance mais augmenter le biais.

- Diminuer h_1 peut capturer plus de détails locaux mais augmenter la variance de l'estimation.

l'évolution des estimateurs en fonction des différentes valeurs de h_2 en fixant $h_1 = 0.1$



A.Impact de h_2 sur les estimations conditionnelles

quand $h_2 = 0.02$ ou 0.04 Très instable avec de fortes oscillations, particulièrement dans la région $x > 0.6$

pour $h_2 = 0.08$ Stabilisation significative, devient plus lisse

pour les valeurs grandes comme $h_2 = 0.15, 0.2$ on voit des oscillations dans l'estimation mais moins en comparant $h_2 = 0.02$ ou 0.04

B.Impact de h_2 sur les estimations résiduelles :

pour les valeurs petites $h_2 = 0.02, 0.04, 0.08$ estimation suit mieux la courbe vraie, meilleure stabilité, et meilleure capture des caractéristiques locales.


quand on augmente $h_2 = 0.1, 0.2$ estimation commence à perdre les détails importants et sur-lissage important.

on résume la Variation de h_2 : - Un h_2 plus grand lisse davantage l'estimation de $\sigma^2(x)$, pouvant masquer des variations locales.

- Un h_2 plus petit peut mieux capturer les variations locales mais être plus sensible au bruit.

étude asymptotique

l'objectif est d'analyser le comportement des estimateurs lorsqu'on augmente la taille de l'échantillon ($n=25,50,100,500,1000$)



1. Biais moyen

Méthode Directe:

Biais initial plus faible pour n petit(25)

croissance rapide jusqu'à $n=150$, se stabilise autour de 0.23 pour $n > 200$

Méthode Résiduelle:

Fort biais initial pour n petit, Décroissance rapide jusqu'à $n=100$ et après augmente et Converge vers environ 0.1,

Méthode Résiduelle a meilleure performance en termes de biais que Méthode Directe.

2.VARIANCE MOYENNE: Les deux méthodes montrent une tendance similaire: Décroissance rapide et converge vers 0.002

3.MSE MOYEN ::


Méthode Directe:

MSE initial($n=25$) élevé, ensuite il y a une Décroissance rapide et Se stabilise autour 0.22 pour les grands valeurs de n .


Méthode Résiduelle:

La méthode résiduelle a un MSE plus faible en comparant avec méthode directe pour toutes les valeurs de n , ce qui la rend globalement plus performante.

Estimateur Direct pour différentes tailles d'échantillon



Estimateur résiduelle pour différentes tailles d'échantillon



pour échantillon petit $n(25,50)$:

Les deux méthodes montrent des performances acceptables avec des biais et variances qui restent comparables. Bien que la méthode conditionnelle puisse être légèrement sensible aux fluctuations dues au bruit, la méthode résiduelle offre des estimations proches de la vraie fonction, surtout si les variations de la variance ne sont pas trop rapides.

Pour des échantillons grands(500,1000):

La méthode résiduelle devient plus précise et surpasse la méthode conditionnelle, grâce à sa capacité à capter les détails de la variance vraie.

conclusion

L'étude approfondie de la sensibilité aux paramètres de lissage et du comportement asymptotique de deux méthodes conditionnelle et par résidus et nous permet de tirer plusieurs conclusions importantes :

1. Sensibilité aux paramètres de lissage :

les deux méthodes montrent une sensibilité aux paramètres de lissages h_1 et h_2 , la méthode Résiduelle moins sensible aux variations des paramètres de lissage que la méthode conditionnelle car elle repose sur la structure des résidus pour estimer la variance conditionnelle, quand les paramètres sont trop petits h_1 ou h_2 l'estimation conditionnelle peut produire des estimations instables et sensibles aux fluctuations locales bien que l'estimation résiduelle peut mieux refléter la variance conditionnelle, quand on augmente h_1 et h_2 l'estimation directe risque sous-estimer les variations locales importantes et le biais potentiellement élevé surtout dans les régions à forte courbure et l'estimation résiduelle peut manquer des changements rapides dans la variation conditionnelle.

2. comportement asymptotique:

les deux estimateurs convergent vers la vraie fonction de variance lorsque la taille d'échantillon augmente, mais la méthode résiduelle démontre une robustesse supérieure car (mse) devient faible, le taux de convergence est généralement de l'ordre $n^{-(4/5)}$ en termes MISE,