

PROJET LDATS2470

zeamari yassine, ,DATS2MS

Table of contents

1	INTRODUCTION	1
2	ANALYSE DESCRIPTIVE	2
2.1	Variables explicatives	2
2.2	Statistiques descriptives	2
2.3	Résumé graphique	3
3	ANALYSE EN COMPOSANTES PRINCIPALES (ACP)	3
3.1	algorithme	4
3.2	analyse les resultats	5
4	ACP à NOYAU (KERNEL PCA)	6
4.1	algorithme	7
4.2	Choix du noyau	7
4.3	analyse les resultats	7
5	COMPARAISON ENTRE PCA ET KPCA	9
6	CONCLUSION	10

1 INTRODUCTION

Ce projet a pour objectif d’explorer et de comparer deux techniques de réduction de dimension : l’Analyse en Composantes Principales (PCA) linéaire et l’ACP à noyau (Kernel PCA), en les appliquant au jeu de données(500 premières observations) [Wine Quality](#).

Dans cette étude, l’analyse se concentre sur la variable “quality”, qui représente la note attribuée au vin rouge. Elle est considérée comme la variable de référence pour évaluer la capacité des méthodes de réduction de dimension à distinguer les différentes classes de qualité. Les autres variables, décrivant les propriétés physico-chimiques du vin, sont utilisées comme variables explicatives. Les deux approches, ACP linéaire et ACP à noyau, sont appliquées sur les mêmes données, et leur efficacité est comparée à travers la clarté des regroupements obtenus selon les niveaux de qualité.

2 ANALYSE DESCRIPTIVE

2.1 Variables explicatives

Variable	Description
fixed acidity	Teneur en acide tartrique, composant principal de l'acidité fixe du vin
volatile acidity	Quantité d'acide acétique, responsable d'un goût vinaigré
citric acid	Acide citrique
residual sugar	Quantité de sucre non fermenté
chlorides	chlorure de sodium, affecte la saveur
free sulfur dioxide	SO_2 libre, préserve l'arôme
total sulfur dioxide	SO_2 total, préservation du vin
density	Densité du vin
pH	Acidité globale
sulphates	Composés sulfatés conservation
alcohol	Degré d'alcool

'data.frame': 500 obs. of 11 variables:

```


$ fixed.acidity      : num  7.4 7.8 7.8 11.2 7.4 7.4 7.9 7.3 7.8 7.5 ...
$ volatile.acidity   : num  0.7 0.88 0.76 0.28 0.7 0.66 0.6 0.65 0.58 0.5 ...
$ citric.acid        : num  0 0 0.04 0.56 0 0 0.06 0 0.02 0.36 ...
$ residual.sugar     : num  1.9 2.6 2.3 1.9 1.9 1.8 1.6 1.2 2 6.1 ...
$ chlorides          : num  0.076 0.098 0.092 0.075 0.076 0.075 0.069 0.065 0.073 0.071 ...
$ free.sulfur.dioxide : num  11 25 15 17 11 13 15 15 9 17 ...
$ total.sulfur.dioxide : num  34 67 54 60 34 40 59 21 18 102 ...
$ density            : num  0.998 0.997 0.997 0.998 0.998 ...
$ pH                 : num  3.51 3.2 3.26 3.16 3.51 3.51 3.3 3.39 3.36 3.35 ...
$ sulphates          : num  0.56 0.68 0.65 0.58 0.56 0.56 0.46 0.47 0.57 0.8 ...
$ alcohol            : num  9.4 9.8 9.8 9.8 9.4 9.4 9.4 10 9.5 10.5 ...

```

2.2 Statistiques descriptives

fixed.acidity	volatile.acidity	citric.acid	residual.sugar	chlorides	free.sulfur.dioxide	total.sulfur.dioxide	density	pH	sulphates	alcohol
Min. : 4.600	Min. :0.1800	Min. :0.0000	Min. : 1.200	Min. :0.03900	Min. : 3.00	Min. : 8.00	Min. :0.9912	Min. :2.740	Min. :0.3300	Min. : 8.70
1st Qu.: 7.400	1st Qu.:0.4000	1st Qu.:0.1075	1st Qu.: 1.900	1st Qu.:0.07300	1st Qu.: 7.00	1st Qu.: 25.00	1st Qu.:0.9964	1st Qu.:3.188	1st Qu.:0.5600	1st Qu.: 9.40
Median : 8.100	Median :0.5300	Median :0.2750	Median : 2.200	Median :0.08200	Median :12.00	Median : 42.00	Median :0.9972	Median :3.290	Median :0.6400	Median : 9.80
Mean : 8.686	Mean :0.5334	Mean :0.3025	Mean : 2.587	Mean :0.09396	Mean :15.04	Mean : 51.44	Mean :0.9974	Mean :3.293	Mean :0.6973	Mean :10.12
3rd Qu.: 9.825	3rd Qu.:0.6450	3rd Qu.:0.4800	3rd Qu.: 2.700	3rd Qu.:0.09300	3rd Qu.:20.00	3rd Qu.: 67.00	3rd Qu.:0.9984	3rd Qu.:3.380	3rd Qu.:0.7800	3rd Qu.:10.50
Max. :15.600	Max. :1.3300	Max. :1.0000	Max. :15.500	Max. :0.61100	Max. :68.00	Max. :165.00	Max. :1.0032	Max. :3.900	Max. :2.0000	Max. :14.00

2.3 Résumé graphique



3 ANALYSE EN COMPOSANTES PRINCIPALES (ACP)

L'ACP cherche à trouver une base orthonormée de directions (appelées composantes principales) qui maximisent la variance projetée des données.

Soit D le jeu de données centré, et Σ sa matrice de covariance. Pour une direction u , la variance projetée des données est donnée par :

$$\sigma_u^2 = u^T \Sigma u$$

L'objectif de l'ACP est donc de maximiser cette variance sous la contrainte que $u^T u = 1$. Ce problème d'optimisation conduit à une équation aux valeurs propres : $\Sigma u = \alpha u$

Autrement dit, les composantes principales sont les vecteurs propres de la matrice de covariance, et les valeurs propres associées correspondent aux variances projetées.

La variance totale du jeu de données est égale à la somme des valeurs propres : $\text{Var}(D) = \sum_{i=1}^d \lambda_i$

Pour choisir le nombre de composantes r à conserver, on calcule la fraction de variance expliquée :

$$f(r) = \frac{\sum_{i=1}^r \lambda_i}{\sum_{i=1}^d \lambda_i}$$

On sélectionne alors le plus petit r tel que $f(r) \geq \alpha$, où α est un seuil de variance expliqué (par exemple $\alpha = 0.95$ pour 95% de variance expliquée).

3.1 algorithme

L'algorithme de l'Analyse en Composantes Principales peut être résumé en quelques étapes clés :

Algorithm 1 Analyse en Composantes Principales (ACP)

Centrage des données:

$\mu \leftarrow \frac{1}{n} \sum_{i=1}^n x_i$ {Calcul de la moyenne}

$Z \leftarrow D - \mathbf{1} \cdot \mu^T$ {Centrage (soustraction de la moyenne)}

Matrice de covariance:

$\Sigma \leftarrow \frac{1}{n} Z^T Z$ {Calcul de la matrice de covariance}

Décomposition spectrale:

$(\lambda_1, \lambda_2, \dots, \lambda_d) \leftarrow \text{eigenvalues}(\Sigma)$ {Valeurs propres}

$U \leftarrow (u_1 \ u_2 \ \dots \ u_d) \leftarrow \text{eigenvectors}(\Sigma)$ {Vecteurs propres}

Sélection de la dimension:

for $r = 1$ **to** d **do**

$f(r) \leftarrow \frac{\sum_{j=1}^r \lambda_j}{\sum_{j=1}^d \lambda_j}$ {Fraction de variance expliquée}

end for

$r \leftarrow \min\{k \in \{1, \dots, d\} \mid f(k) \geq 0.97\}$ {Choix de la dimension réduite}


Projection:

$U_r \leftarrow (u_1 \ u_2 \ \dots \ u_r)$ {Base réduite}

$A \leftarrow \{a_i \mid a_i = U_r^T x_i, \text{ pour } i = 1, \dots, n\}$ {Données projetées}


return A, U_r

3.2 analyse les resultats



Le graphique montre la variance cumulée expliquée par chaque composante principale successive :

- La première composante principale explique environ 95% de la variance totale des données
- La deuxième composante ajoute environ 3,5%, portant le total à environ 99,5%
- selon le critère défini “le plus petit r tel que $f(r) \geq 0,97$ ”, nous avons $r = 2$ C’est-à-dire qu’il faut retenir deux composantes principales pour satisfaire le critère de conservation d’au moins 97% de la variance totale.



- Les vins sont dispersés principalement le long de la première composante principale.
- Les vins de qualité 5 (en vert) montrent la plus grande variabilité et sont présents dans presque toutes les régions du graphique.
- Il n'y a pas de séparation nette entre les différentes catégories de qualité, la relation entre les caractéristiques mesurées des vins et leur qualité perçue est complexe et non-linéaire. Bien que les deux premières composantes principales capturent la majorité de la variance dans les données, elles ne permettent pas une séparation claire des différentes classes de qualité, ce qui suggère que la qualité du vin dépend d'interactions subtiles entre variables qui ne sont pas complètement capturées par une simple réduction linéaire de dimension comme la PCA.

4 ACP à NOYAU (KERNEL PCA)

L'idée de la Kernel PCA est d'effectuer l'ACP dans un espace de caractéristiques où les structures non linéaires deviennent linéaires.

La matrice de covariance dans l'espace $\mathcal{F}$ est : $\Sigma_{\phi} = \frac{1}{n} \sum_{i=1}^n \phi(x_i) \phi(x_i)^T$

Le but est de trouver le vecteur propre principal u_1 tel que : $\Sigma_{\phi} u_1 = \lambda_1 u_1$

Il peut être démontré que u_1 s'écrit comme une combinaison linéaire des points projetés : $u_1 = \sum_{i=1}^n c_i \phi(x_i)$

Le noyau K est utilisé pour résoudre le problème des valeurs propres : $Kc_j = n\lambda_j c_j = \eta_j c_j$

Les valeurs propres η_j et vecteurs propres c_j du noyau fournissent les composantes principales.

La projection d'un point x dans l'espace de caractéristiques sur la composante principale u_1 est donnée par : $u_1^T \phi(x) = \sum_{i=1}^n c_i K(x_i, x)$

La variance expliquée par la $j^{\text{ème}}$ composante principale est : $\lambda_j = \frac{\eta_j}{n}$

4.1 algorithme

Algorithm 2 Kernel Principal Component Analysis (Kernel PCA)

```
1: Calcul de la matrice noyau:
2:  $K_{ij} \leftarrow K(x_i, x_j)$  pour  $i, j = 1, \dots, n$ 
3: Centrage de la matrice noyau:
4:  $K \leftarrow (I - \frac{1}{n} \mathbf{1}_{n \times n}) K (I - \frac{1}{n} \mathbf{1}_{n \times n})$ 
5: Décomposition spectrale:
6:  $(\eta_1, \dots, \eta_n) \leftarrow \text{valeurs\_propres}(K)$ 
7:  $(\mathbf{c}_1, \dots, \mathbf{c}_n) \leftarrow \text{vecteurs\_propres}(K)$ 
8: Calcul des variances:
9:  $\lambda_i \leftarrow \eta_i/n$  pour  $i = 1, \dots, n$ 
10: Normalisation des vecteurs propres:
11:  $\mathbf{c}_i \leftarrow \mathbf{c}_i / \sqrt{\eta_i}$  pour  $i = 1, \dots, n$ 
12: Sélection de la dimension:
13: for  $r = 1$  to  $n$  do
14:    $f(r) \leftarrow \frac{\sum_{i=1}^r \lambda_i}{\sum_{i=1}^n \lambda_i}$ 
15: end for
16:  $r \leftarrow \min\{k \mid f(k) \geq 0.97\}$ 
17: Projection:
18:  $\mathbf{C}_r \leftarrow (\mathbf{c}_1, \dots, \mathbf{c}_r)$ 
19:  $a_i \leftarrow \mathbf{C}_r^T K_i$  pour  $i = 1, \dots, n$ 
20: return  $A = \{a_1, \dots, a_n\}, \mathbf{C}_r$ 
```

4.2 Choix du noyau


- Dans le cadre de la PCA à noyau, le choix du noyau $K(x_i, x_j)$ est crucial car il détermine la manière dont les données sont projetées dans un espace de caractéristiques de dimension potentiellement infinie.
- Pour cette analyse, nous avons choisi le **noyau gaussien**: $K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right)$ où $\sigma = 0.0001$.
- Ce noyau est largement utilisé car il permet de capturer des structures non linéaires complexes dans les données.

4.3 analyse les resultats


Attachement du package : 'kernlab'


L'objet suivant est masqué depuis 'package:ggplot2':

alpha



- Si on applique la règle “le plus petit r tel que $f(r) \geq 0.97$ ” (ligne rouge), il semble que 3 premières composantes principales suffiraient pour satisfaire ce critère.
- les trois premières composantes explique 97,3% de la variance totale des données.





- On observe une certaine séparation des groupes de qualité, bien que les classes soient partiellement superposées, Les observations de qualité 5 sont concentrées sur la partie gauche de la courbe, tandis que les qualités plus élevées (6, 7, 8) apparaissent plus à droite.
- Les vins de qualité 5 et 6 (respectivement en vert et violet) sont les plus nombreux et largement répandus dans l'espace.
- On remarque une structure courbée, typique de structures non linéaires dans les données.

5 COMPARAISON ENTRE PCA ET KPCA

- La PCA permet de capturer une grande partie de la variance avec peu de composantes, mais Le Kernel PCA distribue la variance de manière plus équilibrée entre les composantes principales (Première composante : environ 78%, Deux composantes : environ 93%, Trois composantes : environ 97,3%).
- Le Kernel PCA démontre sa supériorité en révélant une structure non linéaire qui reste invisible avec la PCA linéaire
- Bien que ni l'une ni l'autre méthode n'arrive à séparer parfaitement les classes de qualité, le Kernel PCA montre une meilleure capacité à organiser les données
- Pour une simple réduction de dimension, la PCA linéaire pourrait suffire. Cependant, pour comprendre la structure réelle des données et développer des modèles, le Kernel PCA offre une vision plus riche et plus informative.

6 CONCLUSION

Le Kernel PCA démontre sa valeur ajoutée en révélant une structure non linéaire claire (la parabole) qui reste complètement invisible à la PCA linéaire. Cette découverte fondamentale suggère que:

- Les interactions entre les caractéristiques chimiques du vin sont non linéaires.
- la qualité du vin évolue selon un gradient non linéaire, plutôt que selon des classes bien distinctes.